



■ 파이썬 웹크롤링 과 자동화에 대한 A to Z

(/book/4706)

1. 준비단계 - 스트레칭

1.1 마음가짐 - 무엇이든 할 수 있게 하는 힘

1.2 목 돌리기 - 필요한 파이썬 문법만 알고가자

2. 기초단계 - 유산소운동

2.1 마우스 자동화 - pyautogui 사용법 (1)

2.2 키보드 자동화 - pyautogui 사용법 (2)

2.3 메시지 박스 - pyautogui 사용법(3)

2.4 이미지로 좌표찾기 - pyautogui 사용법 (4)

2.5 사이트 정보 가져오기 - requests 사용법

2.6 사이트 정보 추출하기 - beautifulsoup 사용법 (1)

2.7 사이트 정보 추출하기 - beautifulsoup 사용법 (2)

2.8 사이트 자동화하기 - selenium 사용법(1)

3. 응용단계 - 웨이트 트레이닝

3.0 파이썬 엑셀 다루기 - openpyxl 사용법

3.1 웹스크래핑 예제(1) - 네이버금융 실시간 검색 순위 스크래핑 후 엑셀에 저장하기

3.2 웹스크래핑 예제(2) - 네이버금융 실시간 주가 크롤링하기

Published with WikiDocs (/)



■ 파이썬 웹크롤링 과 자동화에 대한 A to Z (/book/4706) / 2. 기초단계 - 유산소운동 (/85383)

/ 2.7 사이트 정보 추출하기 - bea ... (/86334)

2.7 사이트 정보 추출하기 - beautifulsoup 사용법 (2)

네이버 지식인 크롤링 :: 제목 여러개 뽑기

여러개의 제목을 가져오기 위해서는 copy selector 기능만으로는

구현하기 힘들다는 것을 어느 정도 느끼셨을 겁니다.

copy selector 기능은 하나 특정한 요소를 찾을 때나, 선택자를 잘 모르겠을 때 사용해 주세요.

원하는 데이터를 제대로 선택하기 위해서는 html 구조를 파악해야 합니다 .

html 구조를 파악하는 방법도 구글 개발자 도구를 이용해 볼거예요.

구글 개발자 도구를 잘 활용하면 내가 얻고자하는 데이터가 어떤 html에 담겨있는지 쉽게 알 수 있습니다!

1. 마우스를 구글 개발자 도구의 html 요소에 올려 놓습니다.

2. 해당 html의 차지하고 있는 부분을 확인 합니다.

ul class="basic1" 태그에 마우스를 올려 봤을 때 페이지에 표시되는 영역을 보세요.

10개의 지식인 글들이 다 담겨 있지 않나요?

잘 보이면, 마우스로 html을 옮겨 가면서 사이트에 표시되는 영역을 계속 확인해 보세요.

(이 과정은 처음에는 잘 이해가 안될 수 있습니다.)

너무 이해가 안 가고 어려운 분들은, [HTML CSS]를 이용해서 아주 간단한 페이지 몇 개라도 만들어보면 이 과정이 쉽게 이해될 거예요.

ul class="basic1" 태그 안에 지식인 글들이 담겨 있는 걸 확인 했으니 이 태그를 먼저 beautifulsoup 로 추출해봅시다.

```
import requests
from bs4 import BeautifulSoup

url = 'https://kin.naver.com/search/list.nhn?query=%ED%8C%8C%EC%9D%B4%EC%8D%AC'

response = requests.get(url)

if response.status_code == 200:
    html = response.text
    soup = BeautifulSoup(html, 'html.parser')
    ul = soup.select_one('ul.basic1')
    print(ul)
else :
    print(response.status_code)
```

select_one의 인자로 직접 css 선택자를 입력해서 뽑아 올 수도 있어요.

(ul 태그중 basic1 클래스를 가진 녀석을 뽑아오는 선택자입니다.)

어때요 ul 태그 내용이 잘 출력 되나요?

다음으로 안에 있는 html 구조를 파악해 볼거예요.

```

▼<div class="section">
  ▶<h2>...</h2>
  ▶<div class="option_search">...</div>
  <!-- Search List -->
  <strong class="blind">검색결과</strong>
  ▼<ul class="basic1"> == $0
    ▶<li>...</li>
    ▶<li>...</li>
    ▶<li>...</li>
    ▶<li>...</li>
    ▶<li>...</li>
    ▶<li>...</li>
    ▶<li>...</li>
    ▶<li>...</li>
    ▶<li>...</li>
    ▶<li>...</li>
    </ul>
  ▶<div class="s_paging">...</div>
  <!--kin:navigation maxPage="50" /-->
  ▶<script type="text/javascript">...</script>
  ▶<div class="this_questions" id="bottomQuestionButton">...</div>
  ▶<script type="text/javascript">...</script>
</div>

```

ul 자식태그에는 li태그가 10개 있습니다.

```

▼<ul class="basic1"> == $0
  ▼<li>
    ▼<dl>
      ▼<dt>
        ▼<a href="https://kin.naver.com/qna/detail.nhn?
          d1id=8&dirId=80101&docId=362502659&q=7YyM7J207I2s&enc=utf8
          &section=kin&rank=1&search sort=0&spq=0" target="_blank"
          class="_nclicks:kin.txt _searchListTitleAnchor">
            <b>파이썬</b>
            "배우기 쉬운곳 찾아요!!"
          </a>
        </dt>
        <dd class="txt_inline">2020.07.14.</dd>
        ▶<dd>...</dd>
        ▶<dd class="txt_block">...</dd>
      </dl>
    </li>
    ▼<li>
      ▼<dl>
        ▼<dt>
          ▼<a href="https://kin.naver.com/qna/detail.nhn?
            d1id=1&dirId=10402&docId=344840333&q=7YyM7J207I2s&enc=utf8
            &section=kin&rank=2&search sort=0&spq=0" target="_blank"
            class="_nclicks:kin.txt _searchListTitleAnchor">
              "코딩 "
              <b>파이썬</b>
              " 질문드립니다"
            </a>
          </dt>
          <dd class="txt_inline">2020.01.15.</dd>
          ▶<dd>...</dd>
          ▶<dd class="tag_area">...</dd>
          ▶<dd class="txt_block">...</dd>
        </dl>
      </li>

```

각 li 태그 안에는 dl -> dt -> a 태그 안에 제목이 들어 있습니다.

천천히 어떻게 부모태그이고, 어떻게 자식태그인지 확인해 보세요.

```
import requests
from bs4 import BeautifulSoup

url = 'https://kin.naver.com/search/list.nhn?query=%ED%8C%8CEC%9D%B4%EC%8D%AC'

response = requests.get(url)

if response.status_code == 200:
    html = response.text
    soup = BeautifulSoup(html, 'html.parser')
    ul = soup.select_one('ul.basic1')
    titles = ul.select('li > dl > dt > a')
    for title in titles:
        print(title.get_text())
else :
    print(response.status_code)
```

마지막으로 완성된 코드입니다.

select_one 은 찾은 html 중 가장 첫번째 html 을 가져오고

select 는 찾은 모든 html 을 리스트 형태로 반환 합니다.

li > dl > dt > a 는 자식 선택자를 이용한 것 입니다.

지금까지 beautifulsoup을 이용해 사이트에서 원하는 정보를 추출해 봤습니다.

어떠셨나요?

여기까지 따라온 독학러 분들께 정말 칭찬의 말을 전하고 싶습니다.

*끝까지 포기하지 말고!! *

*앞으로 나아가세요 :) *

마지막 편집일시 : 2020년 7월 17일 1:46 오전

댓글 0 피드백

- **이전글** : 2.6 사이트 정보 추출하기 - beautifulsoup 사용법 (1)
- **다음글** : 2.8 사이트 자동화하기 - selenium 사용법(1)

↑ TOP